

CNV disease detection

using OCT scan images of eyes

Họ và tên – MSSV – Môn học:

1. Phạm Ngọc Duy – 49.01.104.022 – Học máy
2. Phan Quốc Dũng – 49.01.104.019 – Xử lý ảnh số
3. Hoàng Đạo Duy Đạt – 49.01.104.029 – Học máy + Xử lý ảnh số
4. Nguyễn Đình Bình Minh – 49.01.104.090 – Xử lý ảnh số


Abstract — Chụp cắt lớp quang học (Optical Coherence Tomography – OCT) là kỹ thuật then chốt trong chẩn đoán các bệnh lý võng mạc. Việc ứng dụng học sâu nhằm phân loại ảnh OCT tự động giúp giảm tải cho bác sĩ và nâng cao độ chính xác chẩn đoán. Đề án này xây dựng và so sánh ba mô hình mạng nơ-ron tích chập (CNN) gồm ShallowCNN, SimpleCNN và ResidualCNN nhằm phân loại ảnh OCT thành hai nhóm: NORMAL và CNV. Quy trình tiền xử lý bao gồm các phương pháp đáng chú ý như Bilateral Filter, tăng tương phản bằng CLAHE, làm sắc bằng Laplacian và chuẩn hoá. Kết quả cho thấy ResidualCNN đạt hiệu suất cao nhất; tuy nhiên trong bối cảnh yêu cầu tối ưu thời gian, ShallowCNN là lựa chọn hợp lý.

Nội dung

OCT là phương pháp chẩn đoán hình ảnh được sử dụng rộng rãi trong nhãn khoa do khả năng tái tạo cấu trúc võng mạc với độ phân giải cao. Bệnh lý như thoái hóa điểm vàng, tân mạch hắc mạc (CNV) hoàn toàn có thể được phát hiện qua ảnh OCT.

Việc phân tích hình ảnh OCT giữ vị trí quan trọng trong nhãn khoa nhờ khả năng quan sát chi tiết cấu trúc võng mạc và phát hiện các tổn thương vi mô. Tuy nhiên, quy trình chẩn đoán thủ công đòi hỏi nhiều thời gian và chuyên môn sâu. Với sự phát triển mạnh mẽ của học sâu và đặc biệt là CNN, việc tự động hóa phân loại ảnh OCT ngày càng trở nên khả thi và hiệu quả. Đề án này hướng tới xây dựng ba mô hình CNN có mức độ phức tạp khác nhau, đánh giá khả năng phân loại và phân tích ảnh hưởng của kiến trúc mạng đến kết quả.

Mắt CNV (Choroidal Neovascularization) xuất hiện các mạch máu mới mọc bất thường từ mạch mạc, gây rò rỉ dịch và tạo nên các vùng tối trên OCT. Tổn thương CNV làm lớp RPE bị đẩy lên, méo mó, tạo thành khối phòng rõ rệt và phá vỡ cấu trúc lớp võng mạc.



Dataset và xử lý dữ liệu


Dữ liệu gồm hai lớp: NORMAL và CNV, được chia theo tỷ lệ 80% huấn luyện và 20% kiểm định.

Số lượng ảnh như sau:

Lớp	Số ảnh Train	Số ảnh Val	Số ảnh Test
NORMAL	~40,912	~10,228	~2,300
CNV	~29,760	~7,440	~2,300


Để tối ưu hoá khả năng học đặc trưng bệnh lý, một quy trình tiền xử lý ảnh OCT được sử dụng:

1. Chuyển sang grayscale do nhiều đặc trưng bệnh lý quan trọng trong OCT thể hiện ở biến thiên cường độ và cấu trúc lớp võng mạc; OCT thường là ảnh xám.
2. Resize về 224×224 chuẩn phổ biến cho CNN.
3. Bilateral Filter ($d=9$, $\sigma_{\text{Color}}=75$, $\sigma_{\text{Space}}=75$) giảm nhiễu, do tính chất của bilateral filter chỉ làm mờ các pixel có giá trị intensity giống nhau nên giữ biên rất tốt. Trong ảnh OCT võng mạc, bảo tồn biên rất quan trọng để phân biệt mắt thường và mắt CNV. Kích thước kernel là 9 là vừa đủ để giảm nhiễu mà vẫn ít làm mờ.
4. CLAHE ($\text{clipLimit}=2.0$, $\text{tileGridSize}=(8,8)$) giúp tăng cường tương phản cục bộ, làm cho vùng có chi tiết nhỏ (có độ tương phản thấp) nổi bật. tileGridSize : kích thước kernel (8,8) tốt cho ảnh 224×224.



Kết quả cho thấy CLAHE giúp cải thiện đáng kể chất lượng hình ảnh OCT. Entropy của cả hai lớp NORMAL và CNV tăng, phản ánh lượng thông tin trong ảnh lớn hơn sau xử lý. Đồng thời, histogram được mở rộng trên toàn dải cường độ thay vì tập trung ở vùng tối như ảnh gốc. Đối với CNV, vùng gần giữa được tăng cường mạnh, giúp các phần tổn thương nổi bật hơn.


5. Laplacian Sharpening ($lap = cv2.Laplacian$; $img = 0.8img + 0.2|lap|$): làm nổi biên, giúp CNN dễ học các đặc trưng cạnh, cấu trúc lớp võng mạc. Tỷ lệ 8/2 giúp làm nổi bật phần biên vừa phải mà không làm ảnh quá nhiều.




Phân bố gradient cho thấy ảnh CNV có nhiều biên mạnh hơn ảnh NORMAL, phản ánh sự xuất hiện của các cấu trúc bất thường. Sau khi áp dụng Laplacian sharpening, sự khác biệt này được nhấn mạnh hơn: phân bố gradient của NORMAL vẫn tập trung ở giá trị rất thấp, trong khi ảnh CNV có độ trải rộng lớn hơn.

6. Chuẩn hóa / scale to $[0,1]$ giúp gradient ổn định, train tốt hơn.
7. `Expand_dims` thêm một chiều kênh cho ảnh grayscale, chuyển ảnh từ dạng (H,W) thành $(H,W,1)$, để các mô hình CNN có thể xử lý.


- Mắt thường:



- Mắt bệnh:



- So sánh phân bố cường độ (density) trước và sau khi xử lý:




Dựa trên biểu đồ ta có thể thấy tác dụng của các phương pháp xử lý ảnh như sau:

- Ảnh mắt thường:
 - Đỉnh ở vùng 0 – 50 được làm hẹp và cao hơn hẳn, cho thấy Bilateral Filter đã giảm nhiễu và giữ lại biên khá tốt, CLAHE làm tăng độ tương phản cục bộ.
 - Đỉnh ở vùng 200 – 220 trở nên rõ hơn do CLAHE tăng tương phản ở vùng có phản xạ, sharpening làm nổi ranh giới lớp võng mạc.
- Ảnh mắt CNV:
 - Đỉnh chính được dời về vùng 0 – 60 do Bilateral Filter làm giảm nhiễu nhưng vẫn giữ lại cấu trúc biên.
 - Xuất hiện đỉnh phụ cao hơn ảnh mắt thường ở khoảng 180 – 220 do các vùng bị tổn thương của mắt được làm nổi bật.

Các mô hình CNN được xây dựng


Ba kiến trúc CNN được thiết kế nhằm so sánh mức độ trích xuất đặc trưng (Cả ba mô hình đều được thiết kế cho đầu vào ảnh grayscale (1 kênh, kích thước 224×224):

- **ShallowCNN**
 - Hai khối convolution, tốc độ train nhanh.
 - Phù hợp khi tài nguyên hạn chế.




- **SimpleCNN**

- Kiến trúc tiêu chuẩn 3 khối convolution.
- Cân bằng giữa hiệu năng và tốc độ.



- **ResidualCNN**


- Một khối Residual và hai khối convolution
- Sử dụng residual blocks ($x + F(x)$).
- Giảm mất mát gradient, hội tụ ổn định hơn.
- Kỳ vọng đạt độ chính xác cao nhất.



Quá trình huấn luyện sử dụng Adam ($lr = 1e-3$), batch size 64, BCE Loss, huấn luyện 10 epoch trên GPU khi khả dụng.

Kết quả và phân tích

- Train/val loss:




ResidualCNN hội tụ nhanh và loss thấp nhất cả ở train và validation cho thấy khả năng học tốt, ít overfitting.

SimpleCNN có loss cao hơn một chút nhưng vẫn ổn định.

ShallowCNN có khoảng cách giữa train và val lớn hơn, có dấu hiệu overfitting nhẹ.

- Validation accuracy:




ResidualCNN có trung bình val accuracy qua các epoch cao nhất, hội tụ nhanh và ổn định qua các epoch.

SimpleCNN cũng rất tốt, chỉ thấp hơn một chút.

ShallowCNN thấp hơn và cho thấy mô hình nông không đủ khả năng học đặc trưng phức tạp.

- Validation AUC




Cả ba mô hình đều đạt AUC rất cao (~0.997–0.999) cho thấy khả năng phân biệt hai lớp rất tốt.


ResidualCNN và SimpleCNN đạt AUC = 0.999 gần như tối ưu.

ShallowCNN thấp hơn một chút, một lần nữa cho thấy rằng mô hình nông kém hơn.

- Confusion matrix:



- AUC from ROC curve:



- Kết quả cho thấy sự khác biệt rõ rệt giữa ba mô hình:

- **ShallowCNN**


- Hội tụ nhanh nhờ kiến trúc đơn giản nhưng không đủ khả năng trích xuất đặc trưng sâu.
- Biểu hiện overfitting nhẹ, accuracy và AUC thấp nhất.
- Phù hợp cho thử nghiệm nhanh, nhưng hiệu quả phân loại hạn chế.

- **SimpleCNN**

- Cân bằng tốt giữa độ phức tạp và hiệu năng.
- Sâu hơn ShallowCNN cho phép học các đặc trưng tốt hơn.
- Loss và accuracy khá ổn định trong quá trình huấn luyện.
- Đạt AUC gần tối ưu, là lựa chọn đáng tin cậy làm baseline cho bài toán.

- **ResidualCNN**

- Cho kết quả tốt nhất trên tất cả các chỉ số: loss thấp, accuracy cao và AUC gần tuyệt đối.
- Cho phép mô hình học các hàm phức tạp hơn, và giảm thiểu khả năng lỗi trong lúc huấn luyện.
- Hội tụ nhanh và ổn định nhờ residual connections giúp giảm mất mát gradient.
- ROC curve cao và giảm tối đa lỗi nhầm lẫn, đặc biệt trong phân loại các ảnh CNV khó.



Ngoài ra, thời gian huấn luyện giữa SimpleCNN và ResidualCNN không chênh lệch quá nhiều, trong khi ShallowCNN nhanh nhất. Mặc dù ResidualCNN cho kết quả vượt trội, việc

lựa chọn mô hình còn phụ thuộc vào yêu cầu thời gian xử lý. Trong bài toán hiện tại, độ chênh lệch độ chính xác giữa các mô hình không quá lớn, nên ShallowCNN được xem là lựa chọn tối ưu nhất.

Nhận xét tổng quan

- Độ sâu mô hình ảnh hưởng trực tiếp đến kết quả phân loại ảnh OCT.
- Residual connections mang lại cải thiện rõ rệt, đặc biệt trong bài toán hai lớp có nhiễu cao.
- Quy trình tiền xử lý đóng vai trò quan trọng, nâng cao khả năng học đặc trưng của CNN.
- Trong thực tế triển khai, ShallowCNN phù hợp hơn với bài toán khi cho ra kết quả không quá khác biệt với hai mô hình còn lại nhưng có thời gian train thấp hơn đáng kể.

Lời cảm ơn

Tôi xin gửi lời cảm ơn chân thành đến **Thầy Ngô Quốc Việt**, người đã tận tình hướng dẫn và hỗ trợ trong suốt quá trình thực hiện nghiên cứu này. Bên cạnh đó, tôi trân trọng cảm ơn cộng đồng mã nguồn mở cùng các nhóm phát triển PyTorch, OpenCV, NumPy và Scikit-learn, đã cung cấp các công cụ mạnh mẽ giúp hoàn thành bài báo này. Cuối cùng, xin cảm ơn các tổ chức và nhóm nghiên cứu đã chia sẻ bộ dữ liệu OCT công khai, giúp việc thực nghiệm trở nên khả thi và hiệu quả.

Kết luận

Đồ án đã xây dựng thành công ba mô hình CNN để phân loại ảnh OCT và tiến hành so sánh toàn diện về hiệu suất. ResidualCNN và SimpleCNN thể hiện khả năng vượt trội, với độ chính xác và AUC cao, đặc biệt là ResidualCNN với khả năng hội tụ cao và ổn định chứng minh được vai trò của residual blocks. Tuy nhiên, xét trên góc độ ứng dụng thực tế, nơi tài nguyên tính toán và thời gian xử lý được ưu tiên, ShallowCNN lại mang đến sự cân bằng tốt giữa tốc độ và độ chính xác trong bài toán này.

Một số hạn chế:

- Dữ liệu chỉ bao gồm hai lớp (NORMAL và CNV) không mang tính thực tế cao.
- Chưa thực hiện Data Augmentation do giới hạn phần cứng.
- Bộ dữ liệu còn thô sơ, chia train-val-test còn chưa đều, có thể ảnh hưởng đến độ tin cậy của kết quả thực nghiệm.
- Kiến trúc các mô hình có phần đơn giản so với các mô hình hiện đại trên thế giới trong cùng lĩnh vực.

Trong tương lai, hướng phát triển tiềm năng gồm:

- Mở rộng sang phân loại đa lớp (DME, DRUSEN,...)
- Áp dụng thêm các kỹ thuật Data Augmentation chuyên biệt cho ảnh y khoa.
- Sử dụng bộ dữ liệu thực tế chuyên để huấn luyện thêm cho mô hình.
- Triển khai mô hình thành hệ thống hỗ trợ chẩn đoán thời gian thực.

Dataset tham khảo

Kermany, D., Goldbaum, M., Cai, W., et al. (2018). *Large Dataset of Labeled Optical Coherence Tomography (OCT) and Chest X-Ray Images* [Data set]. Mendeley Data. Version 3. <https://doi.org/10.17632/rscbjbr9sj.3> [Sử dụng cho train/val]

Obulisainaren. (2023). *Retinal OCT Image Classification - C8* [Data set]. Kaggle. <https://www.kaggle.com/datasets/obulisainaren/retinal-oct-c8> [Sử dụng cho test]